

RAPPORT CLINIC DE L'IA

PROJET : Prédiction des prix de Nfts



Membre du groupe :

- ✓ Lucrèce LECKAT
- ✓ Likhita YERRA
- ✓ Daniela Micale SAMENY MBOGUET
- ✓ Jessica MBOUNKAP
- ✓ Viany Arnold MBOUYOM LEUMALE

PLAN

Introduction

- Présentation du projet
- Objectifs

Développement

- Etat de l'art

Traitement des données

- Collecte des données
- Nettoyage des données
- Ingénierie des caractéristiques

Analyse exploratoire et statistiques des données

- Visualisation des données
- Test statistiques

Modèle de machine learning et de séries temporelles

- Choix du modèle
- Training
- Evaluation
- Prédiction

Conclusion

Introduction

Les NFT ou jetons numériques non fongibles permettant de représenter la propriété d'actifs numériques ont suscité un intérêt croissant dans le domaine de la blockchain et de la finance numérique. Chacun cherche à savoir le prix d'achat d'un NFT.

C'est dans ce cadre que s'inscrit notre projet. Grâce à l'analyse de données et à l'apprentissage automatique nous tenterons de prédire le prix d'achat d'un NFT, grâce à plusieurs variables.

Développement

Un NFT désigne un fichier numérique auquel un certificat d'authenticité numérique a été attaché. Il est stocké sur une blockchain, et le fichier seul est fongible donc unique. Le premier NFT a été créé en 2014, mais c'est en 2017 qu'il va connaître une ascension énorme grâce à la blockchain Ethereum. Plusieurs œuvres d'art y seront vendues, notamment l'œuvre *Everydays-The first 5000 days* vendu à 69,3 millions de dollars et qui est jusqu'à présent l'œuvre d'art numérique la plus chère de l'histoire des NFT.

Plusieurs travaux ont été faits dans le but de prédire le prix de vente des NFT. Par exemple l'on peut se baser sur l'historique de vente d'un NFT que l'on retrouve sur les marchés et sur la blockchain Ethereum pour prédire non seulement le prix de vente mais aussi le moment d'achat. L'on peut aussi utiliser l'intelligence artificielle pour prédire le prix par le machine et le deep learning.

Traitement des données

Pour mener à bien notre projet, nous avons décidé de nous intéresser à un seul type de NFT, appelé le Bored Ape Yacht Club. C'est une collection unique de 10.000 NFT, représentée par un singe au visage ennuyé et avec des caractéristiques et attributs uniques. C'est la collection de NFT la plus populaire du secteur du crypto.

Les bases de données retraçant l'historique de transactions étant en libre accès sur le site Ethereum, et les sites de marché tels que Open Sea. C'est sur Open Sea que nous avons téléchargé la base de données utilisées pour l'analyse.



#7023

Propriété de RoméoFoxytrotVault

672 vues 47 mises en favoris Les PFP

Meilleure offre

12,4143 WETH 44 392,54 \$

Faire une offre

Historique des prix



Description

Par BoredApeYachtClub

Traits

ARRIÈRE-PLAN Gris 12% Sol: 14,4 ETH	YEUX Yeux écarquillés 5% Sol: 18 ETH	FOURRURE Marron 14% Sol: 14,26 ETH
CHAPEAU Beanie 6% Sol: 20 ETH	BOUCHE Bubblegum... 1% Sol: 26 ETH	

À propos de Bored Ape Yacht Club

Détails

Listes

Offre

Prix	Prix en USD	Quantité	Différence de sol	Expiration	De
12,4153 WETH	44 396,12 \$	1	8 % en dessous	en 10 minutes	DMforBetterPrice__
12,4143 WETH	44 392,54 \$	1	8 % en dessous	en 10 minutes	OTCdeals__
44 392,54 \$	44 392,54 \$	1	8 % en dessous	en 11 minutes	OTCdeals__
44 392,19 \$	44 392,19 \$	1	8 % en dessous	en 10 minutes	DMforBetterPrice__
12,4132 WETH	44 388,61 \$	1	8 % en dessous	en 10 minutes	OTCdeals__

les captures d'écran ci-contre montrent comment est structurée la base de données. Pour chaque transaction, il existe un identifiant unique représenté par le *TokenId*.

```

data.columns
[3] ✓ 0.0s

... Index(['Token_ID', 'Owner', 'OnlyApe', 'BAYCs in wallet', 'RecentSale',
        'RecentSaleUSD', 'RecentSaleDate', 'Platform', 'Floorprice_att',
        'Price-floor', 'highest_offer', 'Highest_offerUSD', 'Floorprice_att2',
        'highest_listing', 'highest_listingUSD', 'Floorprice_att3',
        'Trait rarity', 'Average Rarity', 'Average Rarity_NN',
        'Statistical Rarity', 'Background', 'BackgroundOccurrence', 'Mouth',
        'MouthOccurrence', 'Fur', 'FurOccurrence', 'Eyes', 'EyesOccurrence',
        'Hat', 'HatOccurrence', 'Earring', 'EarringOccurrence', 'Clothes',
        'ClothesOccurrence', 'TraitsCount'],
        dtype='object')

```

Le prix de vente est représenté par la colonne RecentSaleUSD. La base de données contient 10.000 lignes pour 35 colonnes.

Le nettoyage s'appuiera principalement sur la prise en charge des valeurs en doublons, nulles, manquantes et les valeurs aberrantes.

- Les doublons, représentent les lignes qui apparaissent plus d'une fois dans la base de données. Grâce à un code python nous avons pu savoir si la base de données en contenait ou pas.

```

def check_duplicates(data):
    duplicates=data.duplicated().sum()
    if duplicates > 0:
        print("Duplicates !")
        data=data.drop_duplicates()
    else:
        print("No duplicates")
    return
check_duplicates(data)

```

[6] ✓ 0.1s

... No duplicates

Notre base de données ne contient pas de doublons.

- Les valeurs nulles, sont toutes les valeurs n'ayant pas de valeurs définies. Elles sont souvent définies par "NaN" en python.

RecentSale	RecentSaleUSD	RecentSaleDate	Platform	Floorprice_att
NaN	NaN	NaT	NaN	NaN
NaN	NaN	NaT	NaN	NaN
NaN	NaN	NaT	NaN	NaN
NaN	NaN	NaT	NaN	NaN
NaN	NaN	NaT	NaN	NaN

Dans certaines colonnes les valeurs nulles sont présentes sous la valeur *None*, pour un nettoyage efficace on les a remplacés par la valeur par défaut qui est *NaN*. Ensuite nous avons établi le pourcentage de données manquantes dans l'objectif de décider de leur sort : la suppression ou l'amputation.

```
print(f' Pourcentages des données manquantes dans la base de données: {(data.isna().sum().sum())/data.shape[0]}%')
```

Pourcentages des données manquantes dans la base de données: 84.41%

Leur pourcentage étant très élevée, la meilleure solution serait de les remplacer par une valeur par défaut par risque de perdre 80% des lignes de notre base de données. Les colonnes suivantes sont celles qui contiennent les valeurs nulles : 'Owner', 'RecentSale', 'RecentSaleUSD', 'Price-floor', 'Average Rarity_NN', 'Statistical Rarity', 'BackgroundOccurrence', 'MouthOccurrence', 'FurOccurrence', 'EyesOccurrence'. Pour les colonnes numériques, nous allons remplacer les valeurs nulles par la médiane plutôt que la moyenne car elle n'est pas sensible aux données aberrantes ou outliers. Pour les colonnes non numériques, on va utiliser la valeur la plus fréquente comme valeur de substitution.

```
print(f'Pourcentage des valeurs nulles après nettoyage: {(data.isna().sum().sum())/data.shape[0]}%')
```

Pourcentage des valeurs nulles après nettoyage: 0.0%

- Les valeurs aberrantes représentent toutes les valeurs numériques qui sont très loin de la moyenne. Dans notre projet la présence de valeurs très grandes peut s'expliquer par le fait que certains NFT très populaire aient des prix très élevé et d'autres non. Il n'y a donc pas besoin de les supprimer.

```
data['RecentSaleUSD'].describe()

[30] ✓ 0.2s

... count      8.500000e+03
    mean      1.313780e+05
    std       1.575141e+05
    min       9.399992e-02
    25%       6.002512e+03
    50%       9.430203e+04
    75%       2.188132e+05
    max       2.524209e+06
    Name: RecentSaleUSD, dtype: float64
```


Les descriptions statistiques du prix nous montrent que 50% des données sont supérieures à 9,43e+04. Ce qui explique la présence de valeurs très grandes. Après nettoyage, la base de données contient : 8500 lignes pour 35 colonnes.

Le nombre de colonnes étant très grand, nous allons essayer de le réduire. Tout d'abord les colonnes tels que 'BackgroundOccurrence', 'MouthOccurrence', 'FurOccurrence', 'EyesOccurrence', 'Hat', 'HatOccurrence', 'EarringOccurrence', 'ClothesOccurrence', 'Floorprice_att2' ne sont pas importantes pour la prédiction de prix. Ensuite pour mieux appréhender la prédiction de prix et comprendre les variables qui influencent le plus le prix d'un BAYC, nous ferons des analyses statistiques.


Analyse exploratoire et statistiques des données

L'analyse exploratoire et les statistiques des données sont essentielles dans le cadre de la prédiction des ventes NFT (Tokens Non Fongibles). Nous avons permis de mieux comprendre nos données, d'identifier les tendances et les modèles significatifs, et de développer des modèles de prédiction robustes pour anticiper les ventes futures. Nous avons utilisé Power BI pour créer des visualisations interactives peut faciliter la communication des insights et des résultats.


Visualisation des données




Commentaires : La vente par date montre une hausse entre la période d'avril 2022 et juillet 2022, le marché qui récence plus de ventes est Opensea. Des wallets ayant déjà des Nfts de type BAYcs ont des prix plus bas que les autres .




Commentaires : les ventes sont influencées par la rareté des traits



Commentaire : au fil des années les différentes caractéristiques des images impactent sur les ventes




Commentaire : la rareté des traits statiquement parlant durant ses 3 années impactent les ventes




Test statistiques

Le test statistique utilisé dans notre projet est celui de Pearson, il permet de mettre en avant la corrélation entre deux variables numériques. On part d'une hypothèse selon laquelle les variables sont indépendantes les unes des autres.

Grâce à un seuil bien défini l'on va pouvoir rejeter ou accepter l'hypothèse de départ. Dans notre cas le seuil d'acceptation ou de rejet est de 0.05.



Dans le premier cas on voit que le prix est lié à 0.83 avec le Floorprice_att soit 83%. L'on peut déduire que le prix dépend du plafond du prix de plancher. Plus il est haut, plus le prix le sera.



Ici nous voyons que le prix est lié aux différentes caractéristiques du singe. Comme mentionné plus haut, les singes ayant une bouche ennuyée sont ceux dont les prix sont les plus hauts. Les singes ayant des boucles d'oreilles en cross sont les moins chers.

La tendance générale est que le prix dépend principalement du prix de plancher, mais aussi des caractéristiques physiques du NFT, du marché, du nombre de BAYC présent sur la wallet et de la période à laquelle est acheté le NFT.

Modèle de machine learning et analyse des séries temporelles

La prédiction de prix d'un Nfts BAYC est un problème de régression. Pour le résoudre nous allons dans un premier temps utiliser différents algorithmes de régression, les évaluer et choisir celui qui a le meilleur score comme modèle de prédiction. Dans un second temps, étant donné que le prix dépend aussi de la

période d'achat nous allons sortir les tendances par l'analyse temporelle pour avoir une prédiction beaucoup plus précise.

Modèle de machine learning

Pour les modèles, nous avons choisi de tester 7 algorithmes de régression :

- SVM, support vecteur machine vise à trouver un hyperplan qui sépare les données de façon à minimiser les erreurs de prédiction.
- LinearRegression, permet de modéliser la relation linéaire entre une variable dépendante et une ou plusieurs variables indépendantes.
- DecisionTreeRegressor, caractériser par un arbre qui divise l'espace des caractéristiques en sous-espaces et attribue une valeur de prédiction constante à chaque sous-espace
- GradientBoostingRegressor, construit les modèles de manière séquentielles en corrigeant les erreurs résiduelles des modèles précédents
- RandomForestRegressor, construit plusieurs arbres de décision et agrège leurs prédictions pour obtenir une prédiction finale.
- VotingRegressor, combine les prédictions de plusieurs modèles de régression de base
- MLPRegressor, un type de réseau neuronal artificiel avec plusieurs couches cachées, il est capable d'apprendre des relations complexes entre les variables d'entrée et la variable de sortie.

Nous avons séparé notre base de données, en train et en test. La première sera utilisée pour la phase d'entraînement et la deuxième pour la phase de test. 80% des données seront utilisés pour le training et 20% pour le test.

```
✓ X_train,X_test,y_train,y_test=train_test_split(X,y,test_size=0.2)
  print("Train shape:",X_train.shape,y_train.shape)
  print("Test shape:",X_test.shape,y_test.shape)
0.0s

Train shape: (6800, 180) (6800,)
Test shape: (1700, 180) (1700,)
```

...	Model	Score in train	Score in test
0	SVM	-0.055838	-0.067476
1	LinearRegression	0.752543	0.825606
2	DecisionTreeRegressor	1.000000	0.840759
3	GradientBoostingRegressor	0.924866	0.889246
4	RandomForestRegressor	0.977830	0.892857
5	VotingRegressor	0.922565	0.892709
6	MLPRegressor	0.234299	0.123078

Nous voyons ici que le meilleur modèle en entraînement et en test est le RandomForestRegressor avec 97% en training et 89% en test. C'est le modèle choisi.

Pour évaluer les performances de notre modèle, nous utiliserons la RMSE (erreur quadratique moyenne) et la MAE (erreur moyenne absolue).

```

> model=RandomForestRegressor()
  model.fit(X_train,y_train)
  y_pred=model.predict(X_test)
  print(f" L'erreur moyenne: {mean_squared_error(y_test,y_pred)}")
  print(f"L'erreur absolue:{mean_absolute_error(y_test,y_pred)}")
[45]
... L'erreur moyenne: 2238990855.2195053
  L'erreur absolue:19758.27884545303

```

L'erreur moyenne et l'erreur absolue sont très grandes. Ceci pourrait s'expliquer par la présence de valeurs très grandes dans la base de données. En effet la RMSE est très sensible aux outliers.

Le modèle fait une moyenne de 20393 sur chaque prédiction.


```
resultat['erreur'].describe()

[58] ✓ 0.0s

...   count    1.700000e+03
      mean    2.039358e+04
      std     6.727865e+04
      min     8.145446e-01
      25%     8.425967e+02
      50%     5.247343e+03
      75%     1.966329e+04
      max     1.670285e+06
      Name: erreur, dtype: float64
```

Grâce à cette

description statistique l'on comprend mieux pourquoi l'erreur moyenne est très grande, 75% de nos des erreurs sont supérieures à 1.96e04.



Ici l'on comprend que les

prédictions du modèle sont assez fiables malgré les erreurs.

De façon générale le modèle a des scores d'entraînement et de test satisfaisant, les prédictions ne sont pas très précises. Pour avoir des prédictions égales à la valeur de départ il faudrait suivre l'équation suivante :


$$X=y_pred +20393$$

Avec x la valeur prédite égale à celle de départ, y_pred celle prédite par le modèle et 20393 l'erreur moyenne absolue.


Analyse temporelle

Le modèle de Prophet est un algorithme de prévision de séries temporelles développé par Facebook. C'est un grand modèle car il permet de gérer les tendances saisonnières, les valeurs aberrantes et manquantes et fournit des intervalles de confiance pour ses prévisions.

Après avoir appliqué le modèle de Prophet à nos données, nous obtenons les résultats :



Les points noirs représentent les prix réelles (ceux de la base de données), la ligne rouge représente les prédictions du modèle. On voit que les données prédites suivent presque exactement la courbe des données réelles. L'intervalle de confiance est de 95% et est représenté par la ligne bleue.



On voit que le prix est plus haut les mardis, vers 06h51, entre la 50ème et 65ème semaine et environ chaque deux mois. Il est le plus bas en fin de journée, et les samedis.

Grâce à ce modèle nous pouvons prédire les prix les plus haut et les plus bas en fonction d'une période bien définie.

De notre modèle de machine learning et celui de séries temporelles nous pouvons dire que le prix d'un NFT BAYC est élevé ou pas suivant l'heure, le jour d'achat mais aussi le prix du plancher et les caractéristiques physiques de ce dernier.

Conclusion

En conclusion, notre projet a exploré avec succès la prédiction des prix d'achat des NFT Bored Ape Yacht Club (BAYC) en utilisant une approche basée sur l'analyse de données et l'apprentissage automatique. À travers notre méthodologie rigoureuse, nous avons pu atteindre plusieurs objectifs clés.

Tout d'abord, nous avons effectué un traitement minutieux des données en nettoyant les valeurs manquantes et en gérant les valeurs aberrantes, ce qui nous a permis d'obtenir un ensemble de données fiable pour l'analyse. Ensuite, notre analyse exploratoire approfondie nous a permis de découvrir des tendances et des motifs significatifs dans les données, mettant en lumière l'impact de diverses caractéristiques sur les prix des NFT BAYC. En utilisant une variété de modèles de machine learning, nous avons pu construire un modèle de prédiction robuste basé sur les caractéristiques des NFT BAYC, avec le RandomForestRegressor se démarquant comme le meilleur modèle pour notre tâche de prédiction. Malgré certaines limitations et des marges d'erreur à considérer, notre modèle offre des prédictions fiables dans une large mesure. Enfin, en incorporant une analyse de séries temporelles avec le modèle de Prophet, nous avons pu capturer les tendances saisonnières et temporelles qui influencent les prix des NFT BAYC, offrant ainsi une vision plus holistique de la dynamique du marché. Notre projet démontre la valeur de l'analyse de données et de l'apprentissage automatique dans la prédiction des prix des NFT, ouvrant la voie à de futures recherches et applications dans le domaine passionnant de la finance numérique et de la blockchain. À mesure que ce domaine continue d'évoluer, notre travail fournit une base solide pour comprendre et anticiper les tendances du marché des NFT BAYC et d'autres actifs numériques similaires.

Bibliographie

<https://etherscan.io/txs>

<https://fr.cryptonews.com/exclusives/ypredict-rend-marches-boursiers-previsibles-rentables-depechez-vous-prevente-sacheve-bientot.htm>

<https://ethereum.org/fr/developers/tutorials/a-developers-guide-to-ethereum-part-one>

<https://ethereum.org/fr/developers/docs/apis/javascript>

<https://metadata.etherscan.io/api-endpoint/metadata-csv>

<https://www.kaggle.com/datasets/hemil26/nft-collections-dataset>

<https://www.cryptoslam.io/products/api>

<https://opensea.io/rankings>

<https://nftvalueestimator.com/>

https://www.researchgate.net/profile/Omotolani-Kehinde-Osems/publication/365904230_A_COMPARATIVE_STUDY_OF_TWITTER'S_INFLUENCE_ON_NFT_COLLECTIONS_VALUATION_AND_MARKET_PERFORMANCE_-_HOW_INFLUENCE_OF_TWEETS_AFFECT_THE_NFT_MARKETPLACE/links/6388ceac658cec21049d4c12/A-COMPARATIVE-STUDY-OF-TWITTERS-INFLUENCE-ON-NFT-COLLECTIONS-VALUATION-AND-MARKET-PERFORMANCE-HOW-INFLUENCE-OF-TWEETS-AFFECT-THE-NFT-MARKETPLACE.pdf

<https://arxiv.org/pdf/2201.08373.pdf>

<https://arxiv.org/abs/2209.07706>

<https://opensea.io/assets/ethereum/0xbc4ca0eda7647a8ab7c2061c2e118a18a936f13d/6466>

[Bored Ape Yacht Club - Collection | OpenSea](#)

[Bored Ape Yacht Club - Welcome to the BAYC Clubhouse](#)